

Métricas de clasificación

Análisis ROC

Análisis ROC

- ROC: Receiver Operating Characteristic.
- Puede traducirse como: Característica Operativa del Receptor.
- Es una técnica para evaluar clasificadores (principalmente binarios).
- Se empezó usar en detección de señales electrónicas, en los años 1940-1950.
- Herramienta muy usada para evaluar algoritmos de clasificación en áreas de Reconocimiento de Patrones (RP) y Máquinas de Aprendizaje (MA).

Análisis ROC

- Tradicionalmente, las clases son representadas con números 0 y 1 o -1 y 1.
- Estas clases tendrán la nominación de ***clase negativa*** y ***clase positiva*** respectivamente.
- Usaremos algo llamado: Matriz de confusión para crear nuestras métricas de rendimiento.
- Mediante un ejemplo médico veremos su aplicación.

Análisis ROC

- Suponer que se tiene una máquina que, dado datos clínicos de un paciente clasifica al paciente entre enfermo y sano.
- Sano será nuestra clase positiva y enfermo será nuestra clase negativa.
- Entonces, podemos tener 4 escenarios:
 - La máquina dice sano y el paciente está realmente sano (acierto).
 - La máquina dice sano y el paciente está realmente enfermo (error).
 - La máquina dice enfermo y el paciente está realmente sano (error).
 - La máquina dice enfermo y el paciente está realmente enfermo (acierto).

Análisis ROC

- Llamaremos verdadero positivo (True Positive) y verdadero negativo (True Negative) cuando el clasificador da un pronóstico correcto.
 - Llamaremos falso negativo (False Negative) y falso positivo (False Positive) cuando el clasificador se equivoca.
-
- P' = cantidad de ejemplos que dice sano.
 - N' = cantidad de ejemplos que dice enfermo.
 - P = cantidad de ejemplos que realmente son sano.
 - N = cantidad de ejemplos que realmente son enfermo.

		Sano	Enfermo	Total
Dice	Sano	True Positive	False Positive	P'
	Enfermo	False Negative	True Negative	N'
Total		P	N	

Análisis ROC

Las métricas que se pueden calcular directamente de la matriz de confusión son:

$$Accuracy = \frac{TP + TN}{P + N}$$

$$Sensitivity = \frac{TP}{TP + FN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Specificity = \frac{TN}{FP + TN}$$

$$F - measure = \frac{2}{\frac{1}{Precision} + \frac{1}{Sensitivity}}$$

$$fp\ rate = \frac{FP}{N}$$

$$fp\ rate = \frac{TP}{P}$$

donde: TP = True Positive, TN = True Negative

FP = False Positive, FN = False Negative

Análisis ROC

Considere los siguientes resultados de 100 ejemplos positivos y 100 negativos.

A			B			C			C'		
VP=63	FP=28	91	VP=77	FP=77	154	VP=24	FP=88	112	VP=76	FP=12	88
FN=37	VN=72	109	FN=23	VN=23	46	FN=76	VN=12	88	FN=24	VN=88	112
100	100	200	100	100	200	100	100	200	100	100	200
VPR = 0.63			VPR = 0.77			VPR = 0.24			VPR = 0.76		
FPR = 0.28			FPR = 0.77			FPR = 0.88			FPR = 0.12		
ACC = 0.68			ACC = 0.50			ACC = 0.18			ACC = 0.82		

Sea: VPR: la tasa de verdaderos positivos.

FPR: la tasa de falsos positivos.

Análisis ROC

Antes de seguir, tome un momento para discutir con su profesor qué información entrega las métricas vistas. ¿Cómo se interpretan según el contexto?

Volvamos al ejemplo anterior.

- P' = cantidad de ejemplos que dice sano.
- N' = cantidad de ejemplos que dice enfermo.
- P = cantidad de ejemplos que realmente son sanos.
- N = cantidad de ejemplos que realmente son enfermos.

	Sano	Enfermo	Total
Dice Sano	True Positive	False Positive	P'
Dice Enfermo	False Negative	True Negative	N'
Total	P	N	

$$Accuracy = \frac{TP + TN}{P + N}$$

$$Precision = \frac{TP}{TP + FP}$$

¿Le puedo creer al algoritmo cuando dice sano?
¿Qué métrica me sirve para eso?

$$Sensitivity = \frac{TP}{TP + FN}$$

$$Specificity = \frac{TN}{FP + TN}$$

Análisis ROC


Existe algo llamado **espacio ROC**, el cual nos sirve para comparar algoritmos.

B es un clasificador aleatorio (tirar una moneda).

C es el peor.

C' es el mejor.

El **ROC space** sirve para comparar varios clasificadores y como se puede observar, el que está más cerca del punto (0,1), es decir, la esquina superior izquierda, es el mejor.



Existe una forma más completa de ver el rendimiento de varios algoritmos, lo cual se realiza variando un valor umbral que permite crear varios puntos en el espacio ROC para un mismo algoritmo.

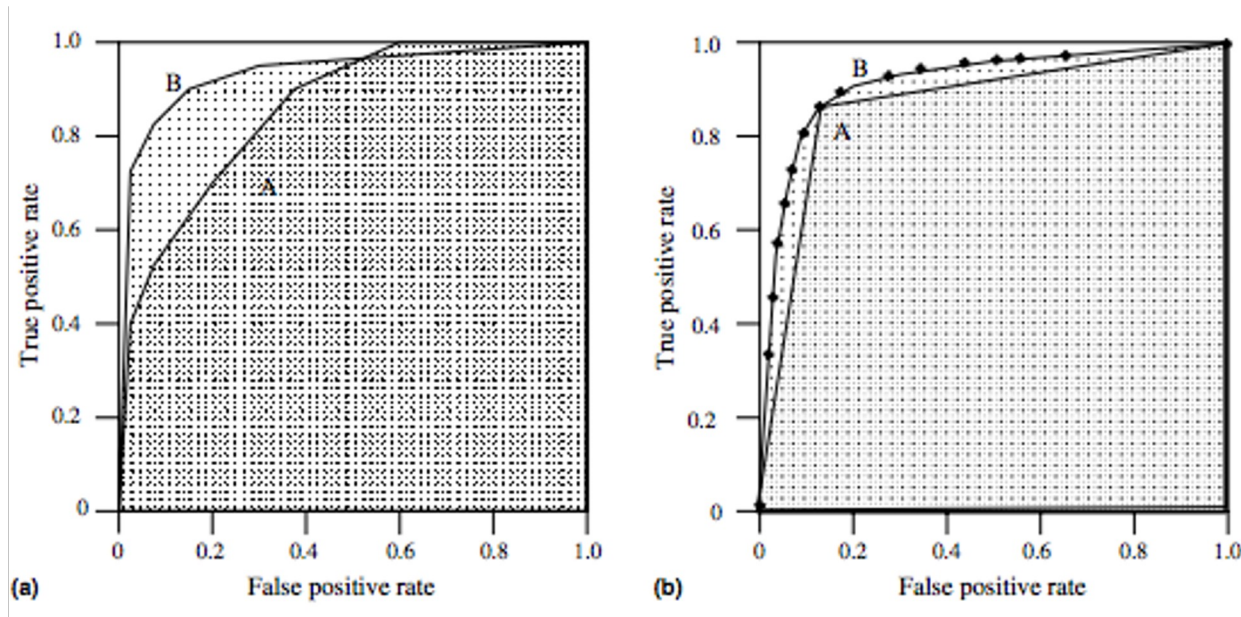
No vamos a ver en detalle cómo se calcula, pero si revisaremos el concepto y como se calcula en scikit-learn.

Análisis ROC

- El área bajo la curva (area under curve - AUC) es un número que indica el rendimiento “promedio” de un clasificador bajo distintos valores de umbral.
- Es una manera de comparar clasificadores de manera general.
- Cada clasificador entrega una curva en el espacio ROC, entonces, el AUC es el área bajo la curva ROC que genera el clasificador.

Análisis ROC

- Clasificador A y B.
- En la imagen (a), el clasificador B es mejor que el A.
- En la imagen (b), el clasificador B es mejor, pero en un punto del umbral, ambos tienen el mismo rendimiento.
- AUC puede ser calculado mediante el método del trapezoide.



En scikit-learn: **`sklearn.metrics.roc_auc_score`**